

Visualizando errores y dispersión

"Visualizando errores y dispersión" © 2021,2022 by Francisco José Madrid Cuevas @ Universidad de Córdoba.España is licensed under CC BY-NC-SA 4.0. To view a copy of this license, visit [\[http://creativecommons.org/licenses/by-nc-sa/4.0/\]](http://creativecommons.org/licenses/by-nc-sa/4.0/)(<http://creativecommons.org/licenses/by-nc-sa/4.0/>).

En muchas ocasiones necesitaremos mostrar el error cometido respecto a una estimación o predicción o visualizar la dispersión de los valores de una variable. Para ello podemos utilizar barras de error en el primer caso o diagramas de cajas en el segundo caso.

Configurando el entorno.

Lo primero es configurar el entorno de ejecución. Véase el cuaderno "Primeros pasos con Matplotlib" para más detalles.

```
In [7]: %matplotlib notebook
import matplotlib as mpl
import matplotlib.pyplot as plt
print('Matplotlib version: {}'.format(mpl.__version__))
import numpy as np
np.set_printoptions(floatmode='fixed', precision=3)
import pandas as pd
from io import StringIO
```

Matplotlib version: 3.5.2

Añadiendo líneas de error a un gráfico de líneas o puntos.

Para representar un gráfico de puntos que muestre barras de error asociadas a cada punto se utiliza la función `Axes.errorbar()`. Esta función añade a las opciones ya vistas de `Axes.plot()`, para dibujar un relación x|y, las opciones para dibujar las barras de error.

Estas barras se pueden dibujar de distintas formas según los valores de los parámetros `xerr`, para mostrar errores en el eje x y `yerr` para mostrar errores en el eje y.

Podemos mostrar un mismo error para todos los puntos, un error simétrico para cada punto, o un error por defecto y por exceso para cada punto.

Además también podemos especificar un formato línea para unir los puntos (como en `plot()`) y otro para las barras de error, o el mismo formato para todo.

Ejercicio 01: Se desea cargar desde un fichero CSV los datos de cotización de una empresa en un objeto `Dataframe`.

La salida esperada debería ser algo parecido a lo siguiente:

	Último	Apertura	Máximo	Mínimo	Vol.	% var.
Fecha						
2021-04-01	3.782	3.815	3.853	3.782	15,16M	-0,92%
2021-04-06	3.780	3.818	3.843	3.776	32,00M	-0,05%
2021-04-07	3.806	3.805	3.878	3.803	20,81M	0,69%

2021-04-08	3.818	3.828	3.841	3.773	12,96M	0,32%
2021-04-09	3.800	3.829	3.840	3.783	9,22M	-0,47%
2021-04-12	3.810	3.793	3.835	3.763	21,35M	0,26%
2021-04-13	3.737	3.800	3.814	3.711	16,68M	-1,92%
2021-04-14	3.736	3.750	3.750	3.682	16,08M	-0,03%
2021-04-15	3.694	3.765	3.786	3.692	12,89M	-1,11%
2021-04-16	3.752	3.700	3.752	3.680	14,80M	1,56%
2021-04-19	3.763	3.760	3.782	3.724	12,87M	0,29%
2021-04-20	3.685	3.761	3.761	3.667	15,49M	-2,07%
2021-04-21	3.703	3.695	3.736	3.657	10,18M	0,49%
2021-04-22	3.694	3.700	3.714	3.657	11,81M	-0,26%
2021-04-23	3.668	3.690	3.720	3.650	42,56M	-0,69%
2021-04-26	3.772	3.692	3.778	3.663	14,82M	2,82%
2021-04-27	3.806	3.774	3.826	3.760	14,84M	0,90%
2021-04-28	3.843	3.832	3.877	3.823	9,54M	0,99%
2021-04-29	3.845	3.863	3.874	3.829	11,83M	0,05%
2021-04-30	3.853	3.850	3.908	3.846	15,09M	0,22%

```
In [8]: #Datos obtenidos desde es.investing.com
file=StringIO(
'''
Fecha    Último  Apertura      Máximo  Mínimo  Vol.    % var.
01.04.2021    3,782    3,815    3,853    3,782    15,16M    -0,92%
06.04.2021    3,780    3,818    3,843    3,776    32,00M    -0,05%
07.04.2021    3,806    3,805    3,878    3,803    20,81M    0,69%
08.04.2021    3,818    3,828    3,841    3,773    12,96M    0,32%
09.04.2021    3,800    3,829    3,840    3,783    9,22M     -0,47%
12.04.2021    3,810    3,793    3,835    3,763    21,35M    0,26%
13.04.2021    3,737    3,800    3,814    3,711    16,68M    -1,92%
14.04.2021    3,736    3,750    3,750    3,682    16,08M    -0,03%
15.04.2021    3,694    3,765    3,786    3,692    12,89M    -1,11%
16.04.2021    3,752    3,700    3,752    3,680    14,80M    1,56%
19.04.2021    3,763    3,760    3,782    3,724    12,87M    0,29%
20.04.2021    3,685    3,761    3,761    3,667    15,49M    -2,07%
21.04.2021    3,703    3,695    3,736    3,657    10,18M    0,49%
22.04.2021    3,694    3,700    3,714    3,657    11,81M    -0,26%
23.04.2021    3,668    3,690    3,720    3,650    42,56M    -0,69%
26.04.2021    3,772    3,692    3,778    3,663    14,82M    2,82%
27.04.2021    3,806    3,774    3,826    3,760    14,84M    0,90%
28.04.2021    3,843    3,832    3,877    3,823    9,54M     0,99%
29.04.2021    3,845    3,863    3,874    3,829    11,83M    0,05%
30.04.2021    3,853    3,850    3,908    3,846    15,09M    0,22%
'''
)
df = pd.DataFrame()

#Pon tu código aquí.
#Sugerencia: carga los datos con read_csv.
#Observa que el separador de columnas es un caracter especial 'tabulador'.
#La primera columna "Fecha" debe ser el índice de filas y contine fechas.
#Debes indicar que el format de fecha tiene el día al principio.
#Además los valores flotantes usan ',' para separar la parte decimal.

#


print(df)
```

```
Empty DataFrame
Columns: []
Index: []
```

Ejercicio 02: Usando el dataframe cargado en el ejemplo anterior queremos representaremos con barras de error los valores mínimos y máximos de cotización de la sesión (técnicamente estos no son errores,

pero podemos visualizarlos como tales).

Intenta ajustar los parámetros para que el resultado sea lo más parecido posible a la siguiente figura.



```
In [9]: import matplotlib.dates as mdates #necesario para gestionar ejes con datos temporales.
from pandas.plotting import register_matplotlib_converters
register_matplotlib_converters() #Requerido por matplotlib si usamos objetos pandas con

fig = plt.figure()
ax = plt.axes()

#Pon tu código aquí.
#Sugerencia: especifica el título, etiquetas de ejes y activa la rejilla.
#en el objeto Axes.

#

#Estas sentencias configuran el eje X para mostrar fechas.
#Esto se estudiará más adelante.
ax.xaxis.set_major_locator(mdates.WeekdayLocator(byweekday=mdates.MONDAY))#Un tick cada lunes
dayFmt = mdates.DateFormatter("%d")#Indicamos un formato de fecha que imprime sólo el día
ax.xaxis.set_major_formatter(dayFmt)#Indicamos que los ticks usen el formato de fecha dado

#Pon tu código aquí.
#Sugerencia: utiliza el comando errorbar().
#Utiliza el parámetro yerr para indicar en un array (2,N) el error por defecto,
#y el error por exceso.
#Recuerda: El índice del dataframe es el eje X.
# Las columnas, Último, (Último-Mínimo) y (Máximo-Último) dan los valores
# a mostrar.

#
```





Gráfico de caja.

Un gráfico "caja" `Axes.boxplot()` (también conocido como gráfico de bigotes "*whisker plot*") permite condensar mucha información sobre la distribución de valores de una variable.

En un gráfico de caja se representan cinco valores de una distribución (ver Figura) y además permite mostrar valores raros (*outlier*). Para una descripción más completa se recomienda leer esta [referencia](#).



La caja se dibuja desde el primer cuartil al tercero. Esta información permite analizar rápidamente la distribución de valores de una variable y también comparar entre las distribuciones de varias variables.

Ejercicio 03: Cargar un fichero donde se almacena la exactitud (*Accuracy*) conseguida por varios clasificadores cuando se han aplicado en varios conjuntos de test.

La salida generada debería ser algo parecido a los siguiente:

	C1	C2	C3
Test			
Test 0	41.195124	58.179442	100.000000
Test 1	40.084025	45.197243	74.461500

Test 2	53.916186	65.116233	24.809018
Test 3	52.708748	59.078461	94.342665
Test 4	50.342881	56.653179	51.577038

```
In [10]: file = StringIO(
'''Test:C1:C2:C3
Test 0:41,19512356955531:58,179442494402025:100,0
Test 1:40,08402469006468:45,19724281341427:74,4615002447282
Test 2:53,91618612768901:65,11623326085783:24,80901846223321
Test 3:52,708747647224136:59,07846091107256:94,34266485081307
Test 4:50,342880673053536:56,65317858383716:51,57703793403086
Test 5:51,959935977730815:80,68135528917625:87,4590004894867
Test 6:52,24205720830521:42,332475597667695:37,64575931058347
Test 7:47,427919175371:61,511637301107825:66,96385536869067
Test 8:49,617861440681594:70,27561007879322:74,35708060746806
Test 9:49,11398357057106:65,7168523881314:62,25817400384894
Test 10:44,14103980544816:49,327244083211916:72,36207265600606
Test 11:46,68275259969946:68,25807361839361:60,1318751882874
Test 12:47,67815785141936:39,6501555822916:69,63002646083551
Test 13:56,76939062603222:57,33328425189499:100,0
Test 14:53,44828205382989:71,36776106665252:85,63759728377201
Test 15:57,28406855178828:66,512889462018:100,0
Test 16:54,04194461978242:66,10210103675635:59,39404418511116
Test 17:55,22557864922575:53,10807747676824:76,60699134349763
Test 18:56,66875103159891:43,01689392094074:100,0
Test 19:54,20354953792935:78,69260105551776:73,1564726825055
Test 20:54,76420040067305:57,835047681417954:83,08581312871534
Test 21:62,82683408828065:54,687662540642286:100,0
Test 22:52,637469757179446:78,24335907879723:73,67410490403417
Test 23:48,25376630323033:76,03333377247561:67,35923558035688
Test 24:59,020170222641816:66,10579661523427:94,96895701360887
Test 25:52,43224918046058:58,99899504200043:89,08047870314059
Test 26:57,12400015736799:57,762480669617446:68,62488455015536
Test 27:44,730802915806365:69,9043065778114:85,89147493932023
Test 28:48,24838546864551:60,7043607693469:71,36495180198067
Test 29:59,73166557734882:56,31331571534148:75,40694698784418
''')

df = pd.DataFrame()
#Pon tu código aquí.
#Sugerencia: usa el método pandas read_csv.

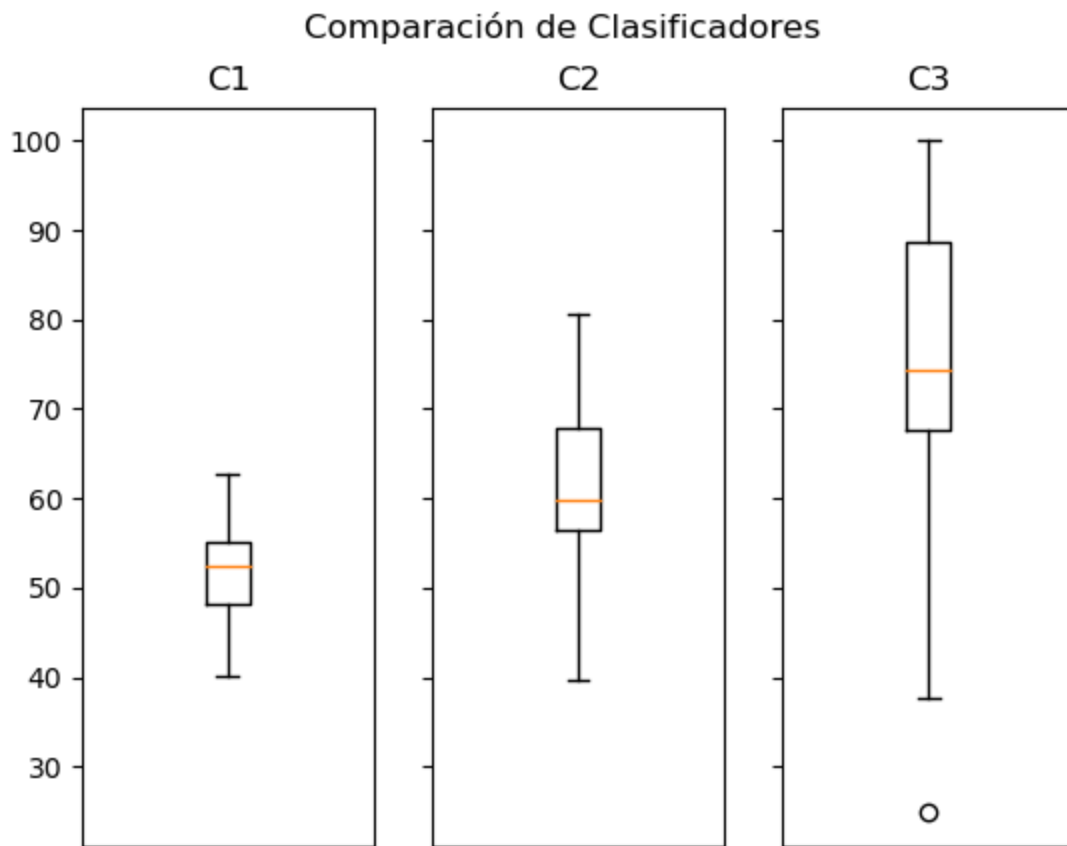
#

print(df.head())
```

```
Empty DataFrame
Columns: []
Index: []
```

Ejercicio 04: Dibuja un gráfico de caja para cada clasificador representado en el dataframe cargado en el ejercicio anterior.

Ajusta los parámetros para que la figura generada se aproxime lo más posible a la siguiente:



```
In [11]: import matplotlib.ticker as ticker #para manipular los ticks de los ejes.
fig = None
axs = None
#Pon tu código aquí.
#Sugerencia queremos generar tres graficos en horizontal. Usa el comando subplots().
#Utiliza los argumentos 'sharey' para que los tres gráficos usen la misma escala en el
#eje Y.

#
#Pon tu código aquí.
#Sugerencia: usa el método suptitle del objeto Figure para añadir un título general.

#
#Pon tu código aquí.
#Dibuja cada caja para el C1 en su Axes correspondiente. Ponle el título.
#Para conseguir que no se utilicen ticks en el eje X debes indicar

#
if axs is not None:
    axs[0].xaxis.set_major_locator(ticker.NullLocator()) #Desactiva los ticks en el eje X

#Pon tu código aquí.
#Dibuja cada caja para el C2 en su Axes correspondiente. Ponle el título.
#Para conseguir que no se utilicen ticks en el eje X debes indicar

#
if axs is not None:
    axs[1].xaxis.set_major_locator(ticker.NullLocator())

#Pon tu código aquí.
```

```
#Dibuja cada caja para el C2 en su Axes correspondiente. Ponle el título.  
#Para conseguir que no se utilicen ticks en el eje X debes indicar
```

```
#  
if axs is not None:  
    axs[2].xaxis.set_major_locator(ticker.NullLocator())
```

In []: